

v3 Pilot — Analysis Report

4 datasets × 3 strategies × 2 N × 2 models | seed=42 | 48 runs

Qwen 2.5 7B & 14B Q4_K_M · distiluse-base-multilingual-cased-v2


- Q1 — 7B vs 14B — O modelo 14B justifica o dobro de VRAM e tempo?
- Q2 — Estratégia de seleção — Qual estratégia funciona melhor: random, score_guided ou diversity?
- Q3 — Budget de anotações — N=50 é suficiente ou N=200 acrescenta?
- Q4 — Dificuldade por dataset — Quão difícil é cada dataset? Boxplot de ROC sobre todos os configs.
- Q5 — Colapso score_guided N=50 — Por que score_guided com N=50 colapsa?
- Q6 — Qualidade das anotações LLM — O LLM anota corretamente? Agreement, precision e recall por modelo e dataset.
- Q7 — Custo × Benefício — Vale gastar mais tempo? Scatter de tempo de execução vs ROC-AUC.
- Q8 — Ranking de configs — Qual a melhor config por dataset? Heatmap de todas as 12 configs × 4 datasets.
- Q9 — Separabilidade dos embeddings — sep_ratio_before por dataset e correlação com ROC-AUC do pipeline LLM (v3).

Q1 — 7B vs 14B

O modelo 14B justifica o dobro de VRAM e tempo?
Heatmap de Δ ROC (14B – 7B) por estratégia x dataset.

Q1 — Δ ROC-AUC (14B – 7B)


Positivo = 14B melhor



Q2 — Estratégia de seleção

Qual estratégia funciona melhor: random, score_guided ou diversity?
Barras por dataset, facetado por N.

Q2 — Estratégia de seleção × Dataset




Q3 — Budget de anotações

N=50 é suficiente ou N=200 acrescenta?

Scatter N=50 vs N=200 — pontos acima da diagonal indicam ganho.


Q3 — N=50 vs N=200
Pontos acima da diagonal: N=200 melhora



Q4 — Dificuldade por dataset

Quão difícil é cada dataset? Boxplot de ROC sobre todos os configs.

Q4 — Dificuldade por dataset
(todos os 12 configs por dataset)




Q5 — Colapso score_guided N=50


Por que score_guided com N=50 colapsa?
Anomalias rotuladas vs ROC resultante.

Q5 — score_guided N=50: colapso de anomalias → ROC degrada

Anomalias rotuladas pelo LLM




ROC-AUC resultante



Q6 — Qualidade das anotações LLM

O LLM anota corretamente? Agreement, precision e recall por modelo e dataset.

Q6 — Qualidade das anotações LLM por dataset e modelo




Q7 — Custo x Benefício

Vale gastar mais tempo? Scatter de tempo de execução vs ROC-AUC.

Q7 — Custo x Benefício: tempo vs ROC


● = 7B ■ = 14B



Q8 — Ranking de configs

Qual a melhor config por dataset? Heatmap de todas as 12 configs x 4 datasets.

Q8 — ROC-AUC por config × dataset
(ordenado por média)



Q9 — Separabilidade dos embeddings

sep_ratio_before por dataset e correlação com ROC-AUC do pipeline LLM (v3).

Q9 — Separabilidade dos embeddings (qwen2.5-7b)

